

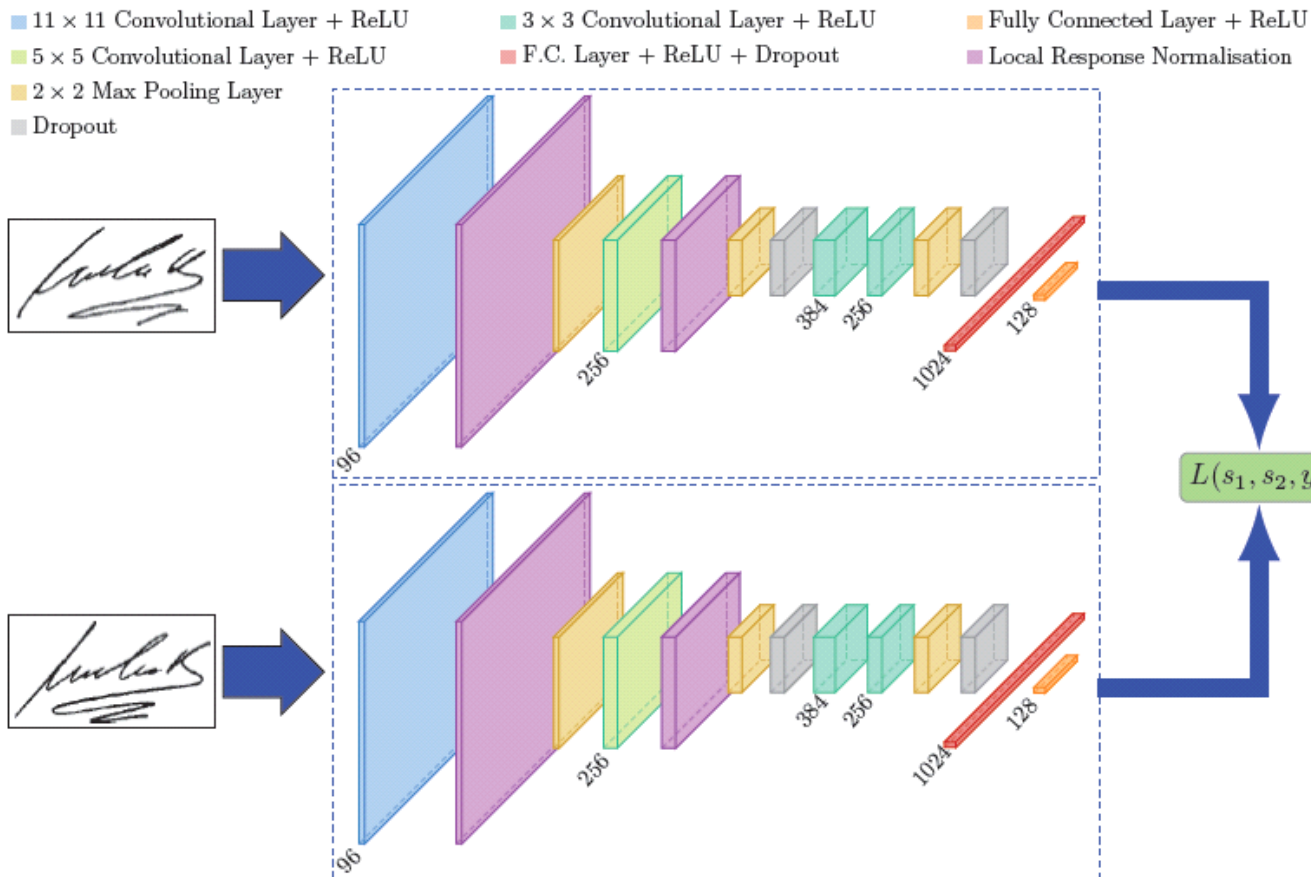
בעידן ה-AI, רשתות נוירונים כמעט טובות בכל משימה, אך רשתות נוירונים אלו מסתמכות על יותר מדי נתונים כדי לבצע ביצועים טובים. אבל, לבעיות מסוימות כמו זיהוי פנים ואימות חתימה, אנחנו לא תמיד יכולים לסמוך על קבלת יותר נתונים, כדי לפתור משימות מסוג זה יש לנו סוג חדש של ארכיטקטורת רשת נוירונים בשם Siamese Neural Networks.

Siamese Neural Networks משתמשת רק במספר מספר בודד של תמונות כדי לקבל תחזיות טובות יותר. היכולת ללמוד ממעט מאוד נתונים הפכה את ה-Siamese Neural Networks לפופולריות יותר בשנים האחרונות.

מה הן Siamese Networks?

Siamese Neural Networks היא ארכיטקטורה בתחום רשתות הנוירונים המכילה לפחות 2 תתי רשתות נוירונים זהות או יותר (למידה זוגית). 'זהה' פירושו, יש להם אותה תצורה (אותן שכבות של רשתות נוירונים) עם אותם פרמטרים ומשקלים. עדכון הפרמטרים משתקף ברשתות. כך ה-Siamese Neural Networks משמש כדי למצוא את הדמיון של ה-Features על ידי השוואת וקטורי (Vectors) התכונות שלו.

בדרך כלל, רשת נוירונים רגילה לומדת לחזות מספר מחלקות (משמע פלטים אפשריים של המודל). זה מעורר בעיה כאשר אנחנו צריכים להוסיף/להסיר מחלקות חדשות לרשת. במקרה זה, עלינו לעדכן את רשת הנוירונים ולאמן אותה מחדש בכל מערך הנתונים. כמו כן, Deep Neural Networks זקוקות לכמות גדולה של נתונים להתאמן עליהן. Siamese Neural Networks, לעומת זאת, לומדת באמצעות 'פונקציית דמיון'. לפיכך, אנו יכולים לאמן אותו לראות אם שתי התמונות זהות (מה שאעשה בפרויקט שלי). זה מאפשר לנו לסווג סוגים חדשים של נתונים\Features מבלי להכשיר את הרשת מחדש.



יתרונות וחסרונות של Siamese Neural Networks

היתרונות העיקריים של ה-Siamese Neural Networks הם:

- מצריכה מספר קטן יותר של תמונות לאימון: כל תמונה תצטרך מספר מצומצם של תמונות על מנת לאמן את המודל.
- מצריך אימון תמונות שונות ללא צורך שינוי המודל: על מנת להוסיף תמונות חדשות שעל המודל לסווג, אין צורך בלשנות את המודל בשונה מרשתות נוירונים רגילות.

לעומת זאת החסרונות של ה-Siamese Neural Networks הם:

- זקוק ליותר זמן אימון מרשתות רגילות: מכיוון ש-Siamese Neural Networks כוללת למידה זוגית, דבר זה איטי יותר מסוג למידה רגיל של סיווג.
- לא מראה את הסתברויות החיזוי: מכיוון שהאימון כוללת למידה זוגית, הוא לא יוציא את ההסתברויות של החיזוי, אלא את המרחק מכל מחלקה.

- Siamese Neural Networks-1 Loss functions

מכיוון שהאימון של רשתות סימיות כרוך בלמידה זוגית, לא ניתן להשתמש ב-Loss Function רגיל, אלא ב-Loss Function שהם.

Triplet loss, הוא Loss Function שבה קלט בסיס (Anchor) מושווה לקלט אותו אנו רוצים שיחזה וקלט שאותו לא רוצים שיחזה. המרחק מהקלט הבסיסי (Anchor) לקלט אותו אנו רוצים שיחזה ממוזער, והמרחק מקלט הבסיס (העוגן) לקלט שאותו לא רוצים שיחזה ממוזער.

$$\mathcal{L}(A, P, N) = \max(\|f(A) - f(P)\|^2 - \|f(A) - f(N)\|^2 + \alpha, 0)$$

במשוואה למעלה, α הוא פרמטר המשמש כדי "להגדיל" את הבדלי המרחק בין צמדים דומים ושונים ב-Triplet loss, $f(A)$ הם התכונות של הקלט הבסיסי שלנו (Anchor), $f(P)$ הם התכונות של הקלט אותו אנו רוצים שהמודל יחזה, $f(N)$ הם התכונות של הקלט אותו אנו לא רוצים שהמודל יחזה.

במהלך תהליך האימון תמונת קלט בסיסי, תמונה שאנו רוצים שהמודל יחזה, תמונה שאנחנו לא רוצים שהמודל יחזה מוזנחת למודל. הרעיון מאחורי זה הוא שהמרחק בין הקלט הבסיסי לתמונות שאנחנו רוצים שהמודל יחזה צריך להיות קטן יותר מזה שבין הקלט הבסיס לתמונות שאנחנו לא רוצים שהוא יחזה.

Contrastive Loss, הוא Loss Function הנמצא בשימוש רב בימינו, בקצרה לפי ה-Loss Function תמונות דומות יהיה בניהם מרחק נמוך יותר לעומת תמונות שונות שלהם יהיה מרחק גדול יותר.

$$(1 - Y) \frac{1}{2} (D_W)^2 + (Y) \frac{1}{2} \{ \max(0, m - D_W) \}^2$$

והגדרנו את D_W שהוא המרחק כ:

$$\sqrt{\{G_W(X_1) - G_W(X_2)\}^2}$$



Predicted Euclidian Distance:- 0.5056638121604919

Actual Label:- Forged Pair Of Signature



Predicted Euclidian Distance:- 1.1049458980560303

Actual Label:- Forged Pair Of Signature